Azure Data Factory Mapping Data Flow para convertir dos archivos CSV con schema diferente a JSON

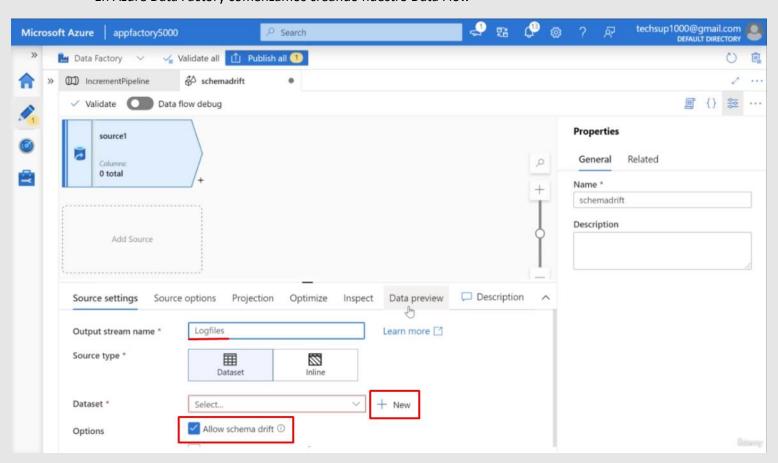
El primer archivo tiene 10 columnas y no tendrá la columna ResourceGroup

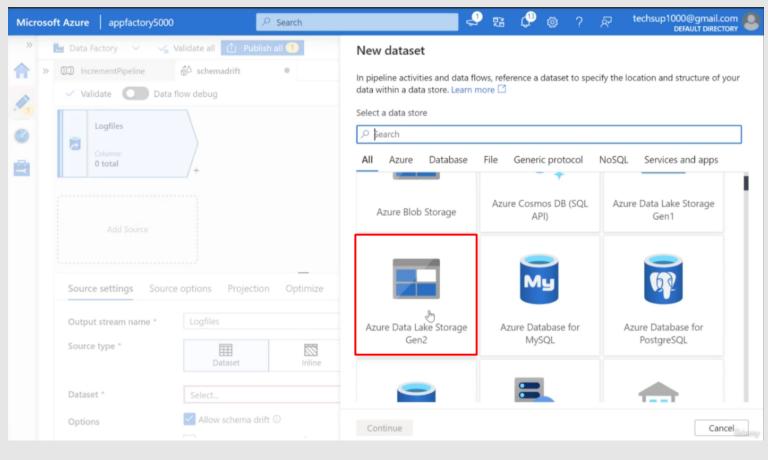
Log-withonecolumnless.csv U X 2-DP-203_-_Data_Engineering_on_Microsoft_Azure > 04 - Design and Develop Data Processing - Azure Data Factory > material > ejemplo_schema_drift > 🔠 Log-withonecolumnless.csv Id, Correlationid, Operationname, Status, Eventcategory, Level, Time, Subscription, Eventinitiatedby, Resourcetype 1,66641e13-d19f-4ce5-aafd-9d5d7befa557,Delete SQL database,Succeeded,Administrative,Informational,2021-06-15T04:44:38.223Z,20c6eec9-2,66641e13-d19f-4ce5-aafd-9d5d7befa557,Delete SQL database,Started,Administrative,Informational,2021-06-15T04:44:21.547Z,20c6eec9-2d8 3,66641e13-d19f-4ce5-aafd-9d5d7befa557,Delete SQL database,Accepted,Administrative,Informational,2021-06-15T04:44:21.7027,20c6eec9-2c 4,e2958162-93d9-4643-a847-82cf25c49930, Delete SqlPools, Succeeded, Administrative, Informational, 2021-06-15T04:44:31.332Z, 20c6eec9-2d80-5,e2958162-93d9-4643-a847-82cf25c49930,Delete SqlPools,Started,Administrative,Informational,2021-06-15T04:44:12.533Z,20c6eec9-2d80-47 6,e2958162-93d9-4643-a847-82cf25c49930,Delete SqlPools,Accepted,Administrative,Informational,2021-06-15T04:44:16.038Z,20c6eec9-2d80-4 7,08cd2e19-477c-4ecc-83a6-575b9ce265e3,Pause SQL Analytics pools.,Succeeded,Administrative,Informational,2021-06-14T17:57:02.240Z,200 8,08cd2e19-477c-4ecc-83a6-575b9ce265e3,Pause SQL Analytics pools.,Started,Administrative,Informational,2021-06-14T17:55:17.612Z,20c6e 9,08cd2e19-477c-4ecc-83a6-575b9ce265e3,Pause SQL Analytics pools.,Accepted,Administrative,Informational,2021-06-14T17:55:18.577Z,20c6 10,d2d9d7c4-2766-4e7d-83fd-c4f07b3d6825,Pause a Datawarehouse database.,Succeeded,Administrative,Informational,2021-06-14T17:56:51.94 11,d2d9d7c4-2766-4e7d-83fd-c4f07b3d6825,Pause a Datawarehouse database.,Started,Administrative,Informational,2021-06-14T17:55:18.393Z 12,d2d9d7c4-2766-4e7d-83fd-c4f07b3d6825,Pause a Datawarehouse database.,Accepted,Administrative,Informational,2021-06-14T17:55:18.478 13,1c735927-517e-470f-bccf-239cdf3b97f8,Create Pipeline Run,Succeeded,Administrative,Informational,2021-06-14T14:24:48.367Z,20c6eec9-14,1c735927-517e-470f-bccf-239cdf3b97f8,Create Pipeline Run,Started,Administrative,Informational,2021-06-14T14:24:45.734Z,20c6eec9-2c 15,0ae558f0-ebbd-4e9e-b3de-406cf39ae0ad,Create or Update any Pipeline.,Succeeded,Administrative,Informational,2021-06-14T14:24:45.429 16,0ae558f0-ebbd-4e9e-b3de-406cf39ae0ad,Create or Update any Pipeline.,Started,Administrative,Informational,2021-06-14T14:24:44.499Z 17,072d5d31-b4b0-4bd1-bfef-088c7faf11eb,Create or Update Dataset,Succeeded,Administrative,Informational,2021-06-14T14:24:44.209Z,20c6 18,072d5d31-b4b0-4bd1-bfef-088c7faf11eb,Create or Update Dataset,Started,Administrative,Informational,2021-06-14T14:24:43.264Z,20c6ed 19,77152ae0-297f-4d10-9179-90d50bec8dac, Create or Update Dataset, Succeeded, Administrative, Informational, 2021-06-14T14:24:44.189Z, 2006 20,77152ae0-297f-4d10-9179-90d50bec8dac,Create or Update Dataset,Succeeded,Administrative,Informational,2021-06-14T14:24:44.189Z,20c6

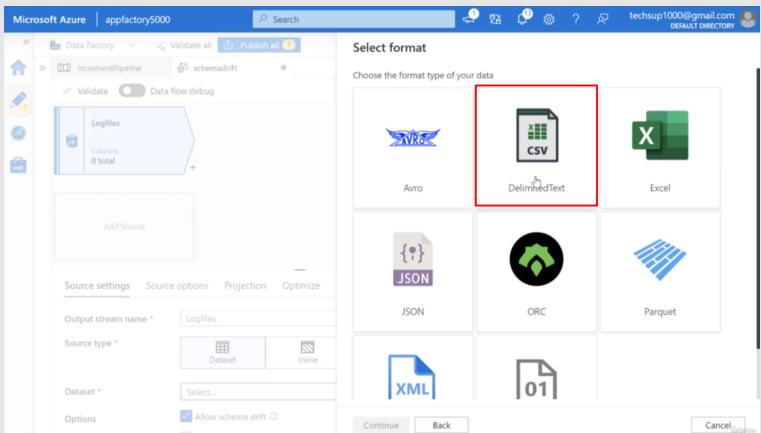
El primer archivo tiene 11 columnas, dado que tiene la columna ResourceGroup



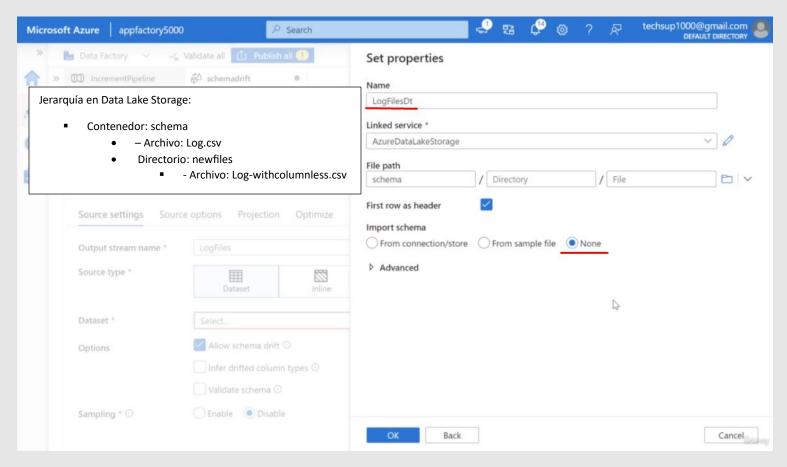
En Azure Data Factory comenzamos creando nuestro Data Flow



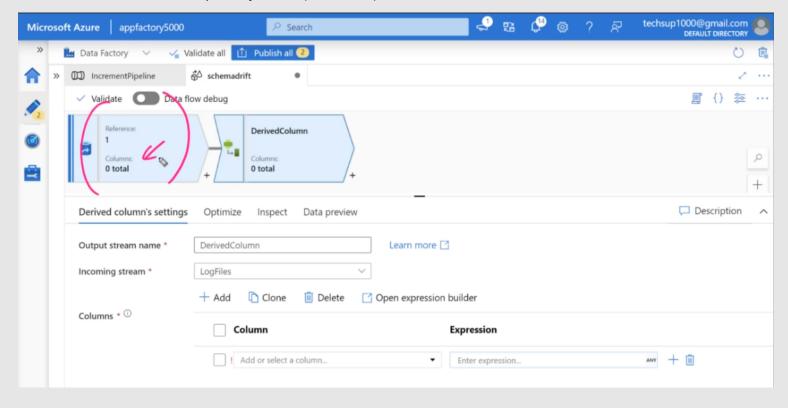




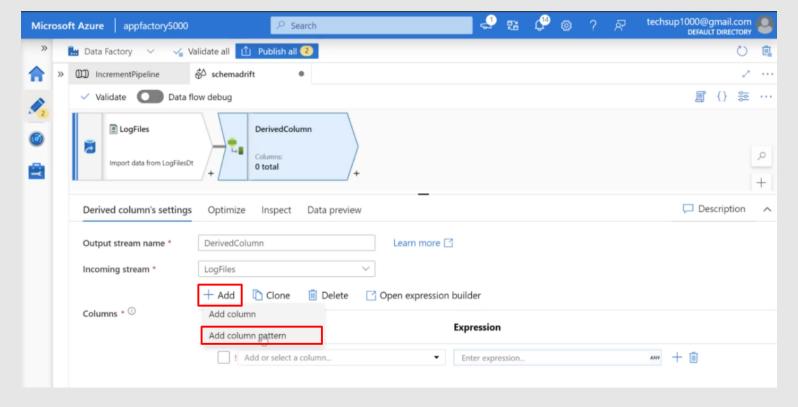
Escogemos la ruta donde se encuentran ambos archivos CSV, en este caso, dentro del contenedor schema. Por otro lado, no importaremos el schema. Ahora, la razón de esto es cuando estamos permitiendo **Schema Drift**, que como puedes ver tiene una opción que se activa automáticamente en estos ajustes. Esto permite que tu esquema sea diferente cuando se trata de archivos fuente. Ahora, si importo el esquema, mirará el archivo Log.csv, que tenemos en el contenedor "schema". Así que, si recuerdas, si vas al contenedor "schema", mirará el archivo Log.csv y tomará o importará el esquema de ahí. ¿Pero qué pasa con el schema del otro archivo? Así que cuando se desea implementar el Schema Drift, es bueno que Azure Data Factory determine el schema en runtime cuando está copiando cada archivo. En lugar de importar el schema y decirle a Azure Data Factory, como debería ser el schema (eso lo hariamos escogiendo la opción "From connection/store"), en lugar de eso, deja que Azure Data Factory, determine el schema en runtime por sí mismo. Es por eso que estoy eligiendo el schema de importación "none".



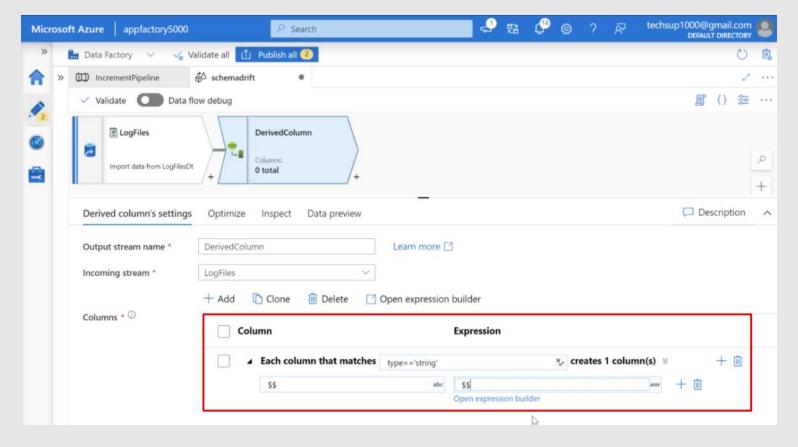
Ahora, antes de que pueda añadir un fregadero, voy a añadir una Derived column. Así que aquí en la Derived column, quiero decir que, cualesquiera que sean las columnas que están aquí (en el paso anterior, en Source), porque se puede ver que no hay columnas que están siendo detectadas por Azure data factory porque le indicamos que no detectara esas columnas. Se quería inferir las columnas en tiempo de ejecución (en runtime).

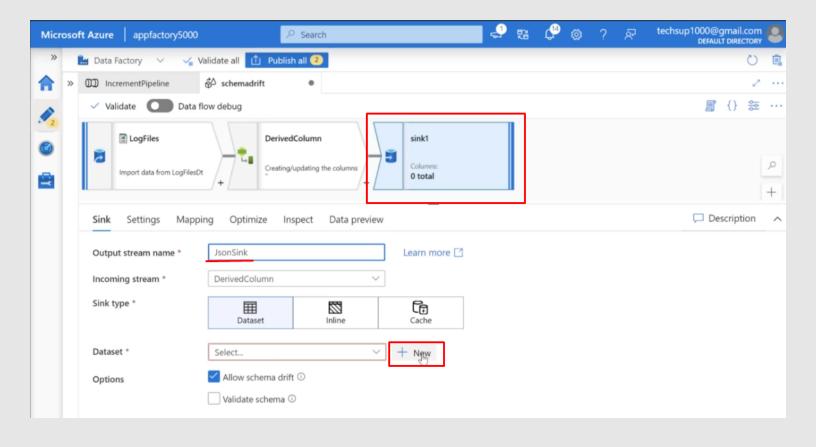


Así que ahora quiero añadir también una Derived column para decirle a Azure Data Factory, que cualquier columna que encuentre en el paso anterior "Source", la derive tal cual. Así que aquí en el mapeo de columna, voy a añadir un patrón de columna.

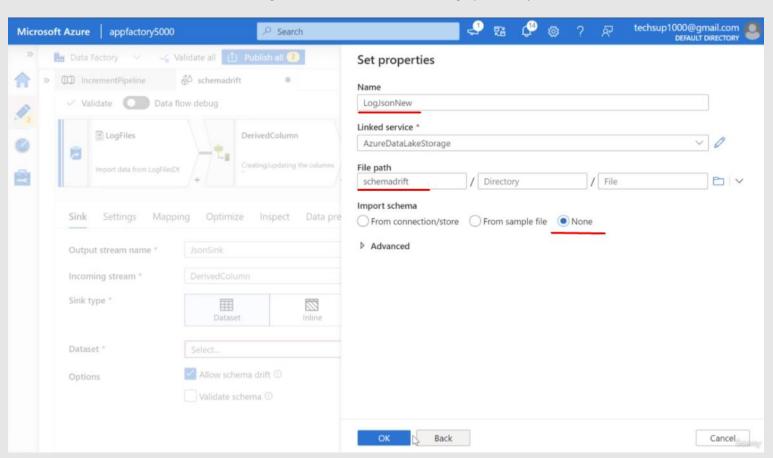


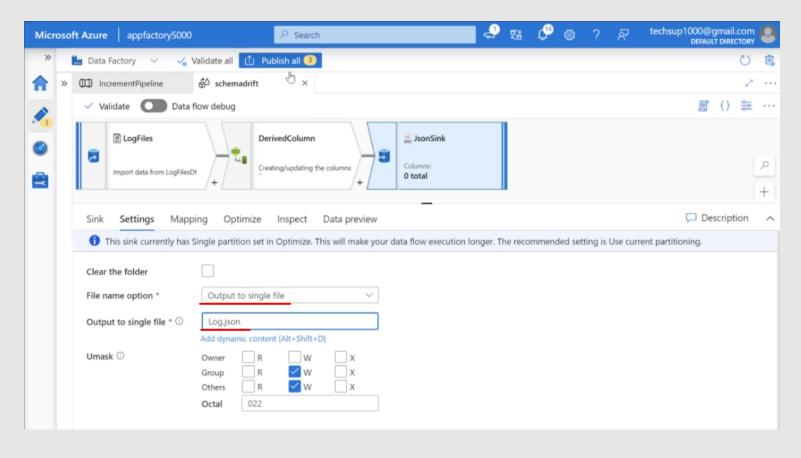
Así que cada vez que hay una columna, del tipo "string" (y en nuestro archivo de ejemplo, todas las columnas son de tipo "string"), a continuación, que mapee cualquiera sea el nombre de la llamada entrante, que en realidad se puede abordar con dos símbolos de dólar "\$\$". Y cuando se copie en el destino, que tome el mismo nombre de columna. Así que, si un nombre de columna es "Id", entonces copiará en el destino con el nombre "Id". Entonces en el Derived Column sólo estamos diciendo "por favor, mapea las columnas como están". Estamos haciendo esto porque recuerda, nuestras columnas no están definidas. Necesitamos que se definan automáticamente en runtime.



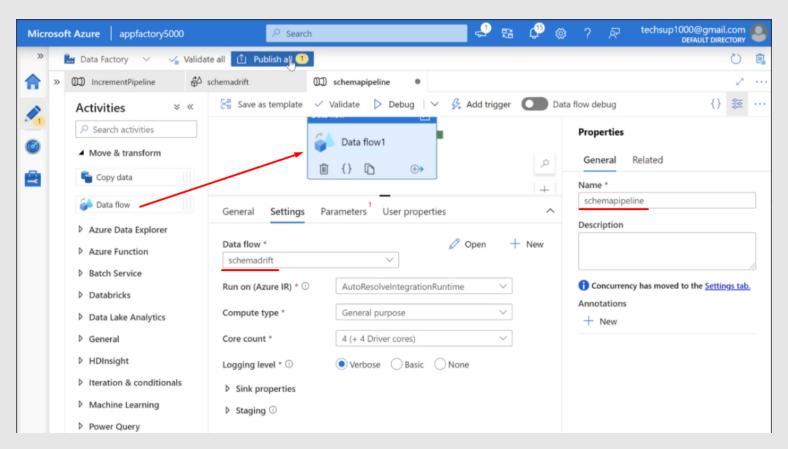


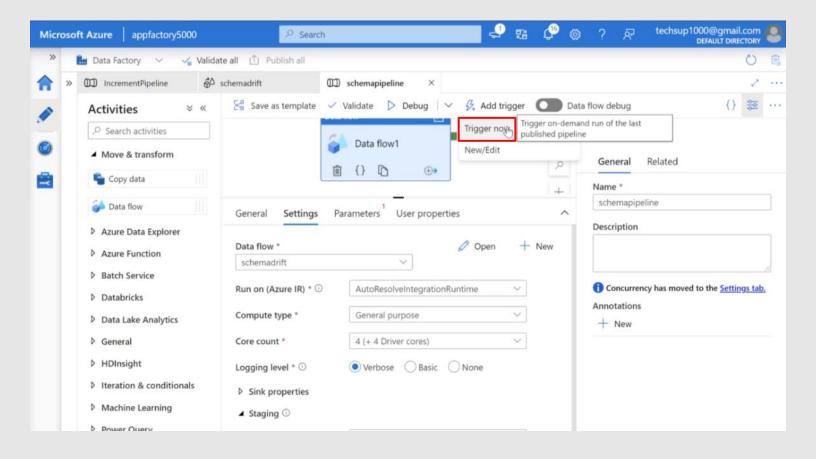
En el dataset de destino escogemos el Azure Data Lake Storage y como tipo de dato JSON





Luego, creamos un Pipeline para ejecutar nuestro Data Flow. Luego **Validamos**, **Publicamos** y **Ejecutamos**.





Si nos dirigimos a nuestro Storage Data Lake

